УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



Ведран Митић 2123

AI модел као претраживач упутства за лекове

Продметни професор:
проф. др Сузана Стојковић
2026.

Списак коришћених скраћеница:

ВИ – Вештачка интелигенција

НМ – Неуронска мрежа

ОПЈ – Обрада природних језика

ВЈМ – Велики језички модел

ПЕФП – Параметарски ефикасно фино подешавање

Садржај

1. Увод 4
2. Задатак одговарања на питања – *Question Answering* 5
3. *BERT* Модел 7
   3.1. Sentence-BERT и векторске репрезентације 9
   3.2. *MPNet* 11
4. Велики језички модели 14
5. Параметарски ефикасно фино подешавање 16
   5.1. LoRA (Low-Rank Adaptation) 16
   5.2. Квантизација 17
   5.3. QLoRA 17
6. RAG 20
7. Специфичности српског језика и преобрада текста у српском језику 22
   7.1. Пресловљавање 22
   7.2. Токенизација 23
   7.3. Лематизација и морфосинтаксичко значење 23
8. Практични део 25
   8.1. Прикупљање и преобрада података 26
   8.2. Креирање векторске базе 27
   8.3. QLoRA фино подешавање 29
   8.4. Системски упит 30
   8.5. Примери употребе 31
   8.6. Проблеми 38
9. Закључак 42
ЛИТЕРАТУРА: 43

1. Увод

Идеја за комуникацијом између човека (корисника) и рачунара (уређаја), односно идеја олакшавања комуникације, била је једна од основних замисли рачунарских стваралаца још од првих пионирских дана ове технологије. Те је тако графички интерфејс прошао дугачак пут од преспајања каблова до директне употребе природног језика какву имамо данас у виду интелигентних система са интегрисаним моделима вештачке интелигенције (ВИ) који тај језик „разумеју“. Иако је први велики „бум“ ВИ доживела почетком 2010-их година у области рачунарског вида, где су различите модификације неуронских мрежа (НМ) готово усавршиле резултате тачности над многим *benchmark* тестовима, у области обраде природних језика (ОПЈ) револуција, може се рећи, се догодила 2017. године са појавом сада већ познате „Трансформер“ архитектуре која је база великих језичких модела (ВЈМ). За ове моделе, специфичне по томе да имају могућност извлачења и разумевања контекста (над великим улазним секвенцама), као и генерисања текста, се можда може рећи да су врхунац управо поменуте комуникације са човеком. Данашњица, а и будућност, је потпуно незамислива без имплементације модела ВИ у различитим уређајима који нас окружују и при том са могућношћу комуникације људским говором, било то путем текстуалног или аудио улаза/излаза.

Због огромног корпуса података над којим су тренирани и могућности скалирања, ВЈМ су хардверски скупи и гломазни, па данашњи изазови пројектовања ВЈМ више леже у начину њихове ефикасне компресије (компресије знања), као и бржем и бољем начину екстракције знања и прилагођавању локалним проблемима[1]. Поред тога, како су светски познати, најчешће коришћени ВЈМ, тренирани углавном на корпусима енглеског језика[2], нужно је пронаћи решења и за прилагођавање мањекорпусним језицима попут српског (и других). Овај рад ће се бавити моделом за одговарање на питања (*Question Answering task*) на српском језику, користећи технологије *RAG* и *LoRA* за екстракцију знања и језичко прилагођавање.

[1] Овде мислим на оно што се у радовима назива *downstream* task. У то спадају све групе проблема ОБЈ, нпр. превођење текста, сумаризација текста, класификација текста, итд. Мада се то може и посматрати као прилагођавање на локалне скупове података који нису били део оригиналног тренинг скупа у фази пре-тренирања. Практично гледано, ово је *fine-tuning*.

[2] Ови модели наравно имају и способност коришћења других језика сем енглеског, али је питање у којој мери квалитет одговора на мањекорпусном језику парира одговору на енглеском. Моја претпоставка је да је тај квалитет на нижем нивоу.

2. Задатак одговарања на питања – *Question Answering*

Задатак одговарања на питања (*Question Answering – QA*) представља један од најважнијих и најсложенијих домена у оквиру ОПЈ. Основни циљ *QA* система јесте да кориснику пружи тачан, директан и контекстуално прикладан одговор на упит формулисан у слободној форми природног језика. За разлику од традиционалних претраживача који као резултат враћају листу читавих докумената или веб-страница на основу поклапања кључних речи, савремени *QA* системи врше семантичку анализу упита, претражују релевантне изворе знања и генеришу конкретан одговор. Оно што *QA* задатак суштински одваја од осталих стандардних задатака ОПЈ (као што су класификација текста, превођење или сумаризација) јесте специфичан скуп захтева и ограничења као нпр. примарност чињеница у односу на креативност. Ово наравно не значи да је креативност ВЈМ скроз избачена, *QA* задаци могу бити екстрактивни, генеративни, затвореног домена и отвореног домена.

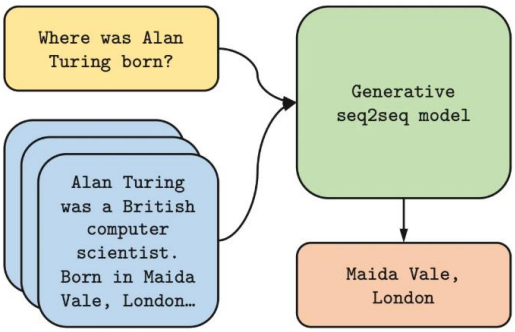
Рани *QA* системи ослањали су се на ручно писана правила, регуларне изразе, онтологије и лексичке базе (попут *WordNet*-а). Ови системи су били изузетно крути, тешко скалабилни и неуспешни у обради неструктурираног језика ван уско дефинисаног домена. Даљим унапређењем алгоритама, *QA* системи су користили фреквенцију речи за проналажење релевантних докумената. Ипак, ове методе пате од проблема синонимије (не препознају да речи „лек“ и „медикамент“ имају исто значење) и синтаксних варијација. Револуција започиње појавом енкодерских модела попут *BERT*-а и *RoBERTa*-е. Уводе се двоструки енкодери као што је *DPR* (*Dense Passage Retriever*) и *SBERT* (*Sentence-BERT*), који питања и одломке текста преводе у густе семантичке векторе унутар заједничког векторског простора. Такви модели омогућили су ефикасно претраживање великих база података, али су и даље били ограничени искључиво на екстрактивни *QA*. Данас, са повећањем капацитета модела и увођењем декодерских архитектура (попут *Llama* модела), *QA* задатак се у потпуности помера ка генеративном приступу. Да би се превазишла ограничења саме параметарске меморије, развијен је концепт *Retrieval-Augmented Generation* (*RAG*). *RAG* комбинује параметарску меморију генеративног ВЈМ-а са непараметарском меморијом (динамичком векторском базом докумената), омогућавајући систему да у реалном времену извлачи тачне чињенице и на основу њих генерише прецизне одговоре.

Упркос изузетном напретку постигнутом савременим архитектурама, област одговарања на питања суочава се са неколико суштинских изазова:

- **Халуцинације (*Hallucinations*):** Велики језички модели су у својој основи статистички генератори следећег токена. Када се од њих затражи одговор на питање за које немају довољно података у својим параметрима, они су склони да генеришу одговоре који изгледају исправно, али су чињенично потпуно нетачни. У стручним применама (нпр. медицина и фармација), халуцинације представљају неприхватљив ризик.
- **Изазови за мање заступљене (мањекорпусне) језике:** Најмоћнији светски ВЈМ обучени су доминантно на корпусима енглеског језика. Примена ових модела на језике са мање доступним ресурсима, попут српског, доноси специфичне проблеме:

    - *Сложена морфологија:* Српски језик садржи богато падежно мењање и глаголске облике, што отежава стандардну токенизацију.
    - *Двописменост (Ћирилица – Латиница):* Модели морају једнако ефикасно да третирају оба писма и пресликавају их у јединствени семантички простор.
    - *Нефикасност токенизатора:* BJM често деле речи мање заступљених језика на велики број ситних подречи (*subwords*), што повећава дужину секвенце, успорава генерацију и заузима више рачунарске меморије.
- **Застаревање и контрола знања:** Знање затечено у параметрима модела је статично и ограничено на тренутак када је процес пре-тренирања завршен, док се глобално знање свакодневно мења.
- **Ограничења контекстуалног прозора и сегментација (*Chunking*):** Иако савремени BJM подржавају све веће улазне контекстне прозоре, прослеђивање превеликих количина неструктурираног текста у улазни упит драстично повећава латенцију, трошкове и ризик од тзв. феномена "губљења информација у средини" (*Lost in the Middle*). Због тога је за успешан *QA* систем од пресудног значаја развој напредних стратегија сегментације текста (нпр. *Header-Based Chunking*) која чува метаподатке и структурни интегритет докумената.
- **Изазови евалуације:** Док се екстрактивни *QA* лако вреднује математичким мерама попут тачног поклапања (*Exact Match*) ili *F1* резултата, вредновање слободно генерисаног текста изискује знатно сложеније (можда и субјективније) методе.

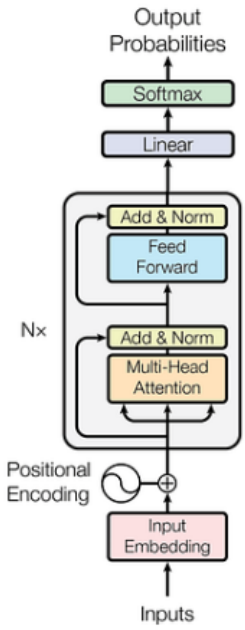
Практични рад ће за имплементацију система за одговарање на питања користити и енкодер и декодер модел. Док је декодер модел искоришћен као BJM за генерацију текста (одговора), енкодер модел је искоришћен при креирању векторских репрезентација текста за векторску базу знања коришћену због RAG механизма, као и претраживач (енгл. *Retriever*).



Слика 1. Основни пример QA система [12]

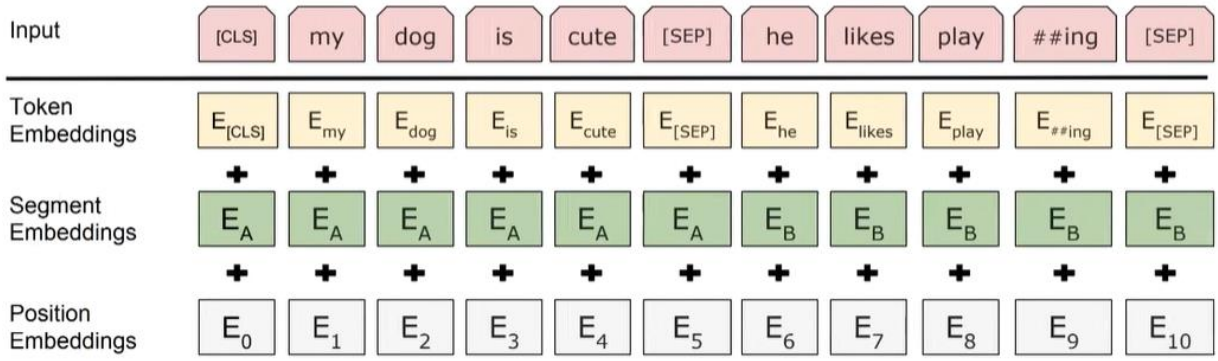
3. *BERT* Модел

Као што је у претходном поглављу разматрано, развој савремених система за одговарање на питања заснован је на потреби да систем прецизно локализује информацију унутар текста или релевантног документа. Традиционални архитектонски приступи нису имали могућност симултаног посматрања и левог и десног контекста утиснутог у дубоке репрезентације речи. Појава *BERT* (енгл. *Bidirectional Encoder Representations from Transformers*) модела означава прекретницу у екстрактивном *QA* задатку, омогућавајући густо семантичко моделирање односа између упита (питања) и контекста (текста који садржи одговор). *BERT* почива искључиво на енкодерском делу оригиналне *Transformer* архитектуре (Слика 2). Основна иновација модела јесте двосмерност: за разлику од класичних једносмерних језичких модела који контекст предвиђају с лева на десно (или десна на лево), *BERT* анализира комплетан низ токена истовремено кроз вишеслојни механизам самопажње (енгл. *Self-Attention*).

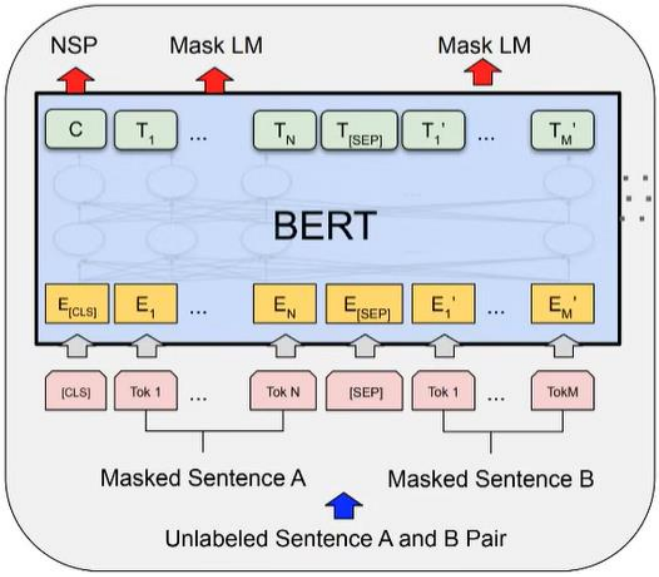


Слика 2. Енкодер архитектура трансформера

Улазна репрезентација *BERT* модела формира се као сума три засебна ветора за сваки токен у низу (Слика 3): (1) Токен ембединг (*Token Embedding*) – Векторска репрезентација самог токена из речника (користи се *WordPiece* токенизација); (2) Сегментни ембединг (*Segment Embedding*) – Разграничава да ли токен припада првој секвенци (нпр. питању, означеном са E_A) или другој секвенци (нпр. контекстном одломку, означеном са E_B); (3) Позициони ембединг (*Positional Embedding*) – Додаје информацију о апсолутној позицији токена у секвенци, будући да сам механизам пажње нема уграђен концепт редоследа.



Слика 3. Векторска репрезентација токена у BERT моделу



Слика 4. Предтренирање BERT-а

За потребе фазе предтренирања (енгл. *Pre-training*), *BERT* користи два ненагледана задатка: (1) Моделирање маскираног језика (*Masked Language Modeling – MLM*) – Случајно одабраних 15% токена у низу замењује се специјалним токеном `[MASK]`. Модел има задатак да реконструише оригиналне токене на основу њиховог двосмерног контекста; (2) Предвиђање следеће реченице (*Next Sentence Prediction – NSP*) – Моделу се прослеђују парови реченица *(A, B)*, а он предвиђа да ли реченица *B* логично следи иза реченице *A*. Овај задатак омогућава моделу разумевање односа између реченица, што је од кључног значаја за одговарање на питања.

За улаз у *QA* систем користи се форма `[CLS] Питање [SEP] Контекст [SEP]`. Токен `[CLS]` представља глобалну репрезентацију целог пара, док се `[SEP]` користи као сепаратор секвенци (Слика 4).

Срж функционисања *BERT* енкодера чини скалирана тачкаста пажња (енгл. *Scaled Dot-Product Attention*). За задате матрице упита (Q), кључева (K) и вредности (V), израчунавање се дефинише као:

$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (1)$$

где d_k представља димензију кључева која служи за скалирање ради спречавања засићења градијента при високим димензијама. Како би модел истовремено обрађивао информације из различитих подпростора репрезентације, користи се *Multi-Head Attention*:

$$MultiHead(Q,K,V) = Concat(head_{1,\dots,}head_h)W^O \quad (2)$$

где је $head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$, а W_i^Q, W_i^K, W_i^V и W^O пројекционе матрице параметара. Оптимизација током *MLM* предтренирања заснива се на укрштеној ентропији над маскираним токенима M:

$$\mathcal{L}_{MLM}(\theta) = -\sum_{i \in M} \log P(y_i | X_{masked}; \theta) \quad (3)$$

где y_i представља стварни токен на позицији i, а X_{masked} маскирану секвенцу токена.

У савременим системима за одговарање на питања заснованим на *RAG* архитектури (Поглавље 6), *BERT*[3] је изгубио своју улогу претраживача (енгл. *Retriever*), али је његова енкодерска идеја остала у виду модернијих модела (*BGE, E5, Voyage, OpenAI text-embedding-3*).

3.1. Sentence-BERT и векторске репрезентације

Упркос свим побољшањима, коришћење стандардног *BERT* модела (или *RoBERTa*) за израчунавање семантичке сличности међу хиљадама докумената у реалном времену је рачунски изузетно скупо. Формирање парова кроз *Cross-Encoder* захтева $O(M \cdot N)$ пролаза кроз мрежу. Са друге стране, `[CLS]` вектор класичног *BERT* модела без додатног подешавања често даје лоше резултате када се директно мери косинусна сличност између реченица. Како би се овај проблем превазишао и омогућило скалабилно векторисање текстова у просторе високе димензије, развијен је *Sentence-BERT* (*SBERT*)[3]. *SBERT* додаје слој за сажимање (*pooling*) и обучава (*fine-tune*) мрежу преко сијамске/тројне архитектуре како би добијена реченична векторска репрезентација постала семантички смислена и погодна за директно поређење помоћу косинусне сличности.

Сијамска мрежа је архитектура са две идентичне неуронске мреже које деле потпуно исте тежине и параметре, а уместо спајања две реченице у један улаз, једна реченица (A) се пропушта кроз прву мрежу, док се друга реченица (B) пропушта кроз другу. На овај начин

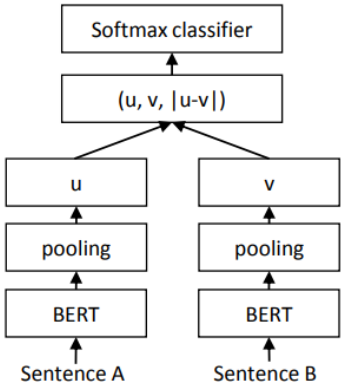
[3] Иако је остварио значајан напредак, класичан *BERT* модел поседује конструктивна ограничања у контексту сложених *QA* и *RAG* система: дужина секвенце, неефикасност *NSP* задатка... У раду је овом моделу посвећено поглавље из два разлога: (1) Због описа основне идеје трансформер архитектуре (која се користи и код декодер модела) и енкодер модела (креирања ембединга); (2) Због тога што оригинални рад о *RAG* механизму базира претраживач управо на овом моделу.

било које ажурирање параметара током обуке се односи на обе стране подједнако, а добијени излазни вектори се пореде косинусном сличношћу.

Тројна мрежа је проширење сијамске архитектуре која користи три идентичне мреже са дељеним тежинама и истовремено посматра три улаза: референтну реченицу (*Anchor, a*), позитивну реченицу (*p*) која је семантички слична или повезана са референтном и негативну реченицу (*n*) која је различита или неповезана са референтном. Рачунањем функције губитка на излазу и оптимизацијом, мрежа се приморава да растојање између *a* и *p* буде мање од растојања између *a* и *n* за најмање дефинисану вредност епсилон:

$$\max(\|s_a - s_p\| - \|s_a - s_n\| + \epsilon, 0) \quad (4)$$

при чему s_x представља векторску репрезентацију реченице *x*. На крају тренинга, векторски простор је организован тако да су семантички блиске реченице близу једна другој, а различите на одређеној удаљености.



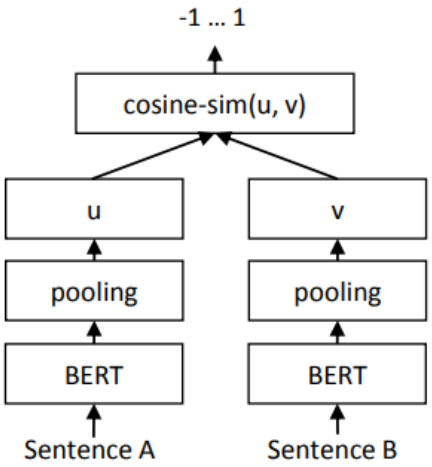
Слика 5. SBERT Архитектура сијамске мреже [3]

Процес у *SBERT*-у се одвија у три корака (Слика 5): (1) Реченица се дели на токене и пролази кроз слојеве енкодер модела, па сваки токен на излазу добија свој појединачни вектор, (2) сажимање – *SBERT* узима све излазне векторе токена и комбинује их у један фиксни вектор за целу реченицу помоћу сажимања средњом вредношћу (*MEAN pooling*[4]), (3) фино-подешавање – параметри енкодера се кроз сијамску или тројну структуру прилагођавају током обуке тако да добијени реченични вектор прецизно одражава значење целе реченице. Након финог-подешавања, финални слојеви (класификациони или регресиони) се уклањају, а у инференци се за добијање ембединга реченице користи само прилагођени ембединг модел са слојем за сажимање (Слика 6). Овако научен модел има способност извлачења суштине из реченице и њеног смештања у векторски простор у област близу семантички сличних реченица.

Код система за претраживање информација, уколико имамо велику базу докумената, *BERT* би за сваки унети упит морао да израчунава пролаз кроз мрежу у пару са сваким документом

[4] Постоје још и тактике коришћења *MAX* сажимања (максимум по димензијама) и претходно спомињаног `[CLS]` токена (узимање вектора првог токена), али је кроз рад [3] емпријски доказано да је *MEAN* сажимање постигло најбоље резултате.

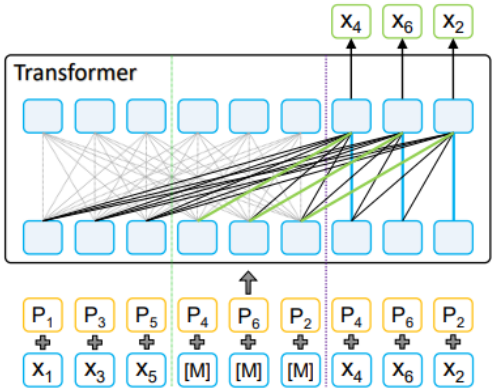
посебно, што траје сатима. Са друге стране, *SBERT* смањује време претраге на неколико секунди, јер се комплексан рад модела извршава само једанпут (*offline*) у фази тренирања, а рачунање вектора се врши само за реченицу упита. Тај вектор се онда упоређује са унапред сачуваним векторима из базе помоћу косинусне сличности или специјализованих индекса за векторску претрагу, а резултат су документи чији је вектор најближи вектору упита.



Слика 6. SBERT архитектура при инференци [3]

3.2. *MPNet*

У оквиру концепта *Sentence-BERT* (*SBERT*) енкодера разматраног у претходном поглављу, квалитет и геометријска прецизност векторског простора директно зависе од основне (*backbone*) архитектуре модела која се подвргава процесу финог подешавања преко сијамских или тројних структура. Иако је оригинални *SBERT* користио класичан *BERT* као основу, савремени *RAG* системи захтевају знатно прецизније енкодере за семантичку претрагу. У практичном делу рада за генерисање векторских репрезенетација (Поглавље 8) користи се модел `sentence-transformers/paraphrase-multilingual-mpnet-base-v2` [12]. Овај модел представља природни наставак *SBERT* концепта, где је традиционална *BERT* основа замењена напреднијом *MPNet* (*Masked and Permuted Pre-training*Слика 7) [4] архитектуром.



Слика 7. Структура MPNet-а [4]

Да би се разумела иновативност MPNet архитектуре, неопходно је анализирати два фундаментална приступа за предтренирање енкодерских модела који су му претходили: *MLM* (*Masked Language Modeling*) примењен у *BERT*-у и *PLM* (*Permuted Language Modeling*) примењен у *XLNet*-у. Као што је већ речено у Поглављу 3. *MLM* приступ маскира проценат токена и покушава да их предвиди на основу преосталих токена, оптимизујући функцију грешке [4]:

$$\mathcal{L}_{MLM}(\theta) = \mathbb{E}_{z\in Z_n}\left[\sum_{t=c+1}^{n} \log P(x_{z_t}|x_{z_{\leq c}}, M_{z_{>c}}; \theta)\right] \tag{5}$$

где $M_{z_{>c}}$ представља скуп маскираних токена на позицији $z_{>c}$. Форула (5) показује да *MLM* претпоставља да су сви маскирани токени међусобно независни за задати немаскирани контекст, што у пракси врло често није случај, па долази до занемаривања узајамне семантичке зависности између маскираних токена.

Са друге стране, да би превазишао овај проблем, *XLNet* уводи пермутовано језичко моделовање (*PLM*). Сада се, за дати низ токена дужине n, посматрају све могуће пермутације редоследа индекса Z_n и врши ауторегресивно предвиђање с десна на лево над пермутованим низом [4]:

$$\mathcal{L}_{PLM}(\theta) = \mathbb{E}_{z\in Z_n}\left[\sum_{t=c+1}^{n} \log P(x_{z_t}|x_{z_{<t}}; \theta)\right] \tag{6}$$

где z_t означава *t*-ти елемент у пермутацији z, $z_{<t}$ све елементе који претходе позиции *t* у тој пермутацији, а *c* број немаскираних токена. Међутим, овакав приступ губи информацију о позицији токена који долазе након њега у перутацији, однсосно контекст читаве реченице.

MPNet архитектура (Слика 7) кроз јединствен математички оквир синтетише добре особине оба приступа и дефинише своју функцију циља као:

$$\mathcal{L}_{MPNet}(\theta) = \mathbb{E}_{z\in Z_n}\left[\sum_{t=c+1}^{n} \log P(x_{z_t}|x_{z_{<t}}, M_{z_{>c}}; \theta)\right] \tag{7}$$

Другим речима, када предвиђа токен x_{z_t}, *MPNet* користи све претходно предвиђене токене у пермутованом низу $x_{z_{<t}}$ (задржава међусобну зависност излазних токена) и све позиционе информације о маскираним токенима из целе реченице $M_{z_{>c}}$ (одржавање позиционог знања).

Да би се омогућила ефикасна обука према (7), *MPNet* имплементира проширени механизам двоструке самопажње (*Two-Stream Self-Attention*) уз увођење тзв. компензације позиција (*Position Compensation*) [4]. Архитектура одржава два паралелна тока информација унутар слојева трансформера:

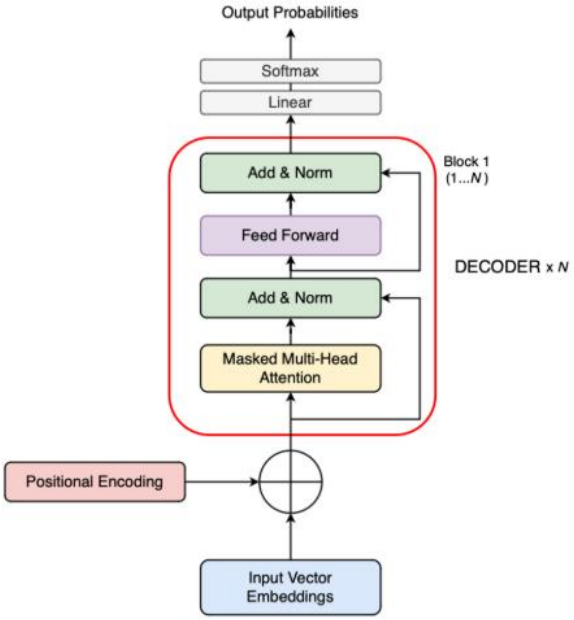
- Ток садржаја (*Content Stream*): Прима и токене и њихове апсолутне позиције $x_i + P_i$. Његова улога је да извуче пуну контекстуалну репрезентацију немаскираног дела текста.
- Ток упита (*Query Stream*): Прима само позиционе ембединге и маскиране токене ($[M] + P_i$), а не и саме реалне садржаје токена који се предвиђају. Његов задатак је да

предвиди токен на задатој позицији искључиво на основу претходно доступних токена и укупне позиционе структуре.

Компензација позиција унутар матрице пажње осигурава да чак и у оквиру *Query Stream*-а, током сваког корака предвиђања токена x_{z_t}, модел прослеђује позиционе ембединге свих *n* токена оригиналне реченице. На тај начин *MPNet* користи 100% позиционих информација целе секвенце уз истовремено очување ауторегресивног моделирања излаза.

4. Велики језички модели

За разлику од енкодерских модела (попут *BERT*-а и *MPNet*-а) који су примарно пројектовани за двосмерну семантичку анализу и формирање векторских репрезентација, савремени ВЈМ ослањају се претежно на декодерску архитектуру трансформера(*Decoder-only*, Слика 8). Основни задатак декодерских модела јесте генерација текста кроз ауторегресивно предвиђање следећег токена на основу свих претходно генерисаних токена и улазног упита.



Слика 8. Архитектура типичног декодер модела [13]

Архитектура савремених декодера изоставља слој укрштене пажње (*Cross-Attention*) карактеристичан за оригиналну енкодер-декодер архитектуру и користи искључиво узрочну самопажњу (*Causal Self-Attention*). Овај механизам онемогућава да модел приликом анализе и предвиђања тренутног токена види будуће токене у низу, чиме се строго чува узрочно-последични (ауторегресивни) карактер генерације. Скалирана тачкаста пажња са применом узрочне маске дефинише се додавањем матрице каузалне маске M у формулу (1):

$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}} + M)V \tag{8}$$

где M има елементе:

$$M_{ij} = \begin{cases} 0, i \geq j \\ -\infty, i < j \end{cases}$$

Примена маске M осигурава да за било коју позицију i, тежине пажње према позицијама $i > j$ постану нула након примене *Softmax* функције. Вероватноћа генерисања целокупне излазне секвенце токена $Y = (y_1, y_2, \dots, y_N)$ за дати улазни контекст рачуна се као производ условних вероватноћа свих појединачних токена, док се оптимизација заснива на простој минимизацији унакрсне ентропије на излазу.

Изазови ове врсте модела су веома слични као код предхотно разматраних енкодерских модела. Међутим, због много веће заступљености и скалабилности, данашњи ВЈМ, па чак и они јавно доступни (*open-source*), захтевају огроман хардверски капацитет рад, што чини приступачност као један од главнијих проблема широке заједнице[5]. У оквиру практичног дела овог рада (Поглавље 8), декодерски ВЈМ преузима централну улогу генератора одговора унутар *RAG* система. За разлику од ранијих екстрактивних *QA* система у којима се одговор само исеца из пронађеног одломка, у раду се користи савремени декодерски модел (`Llama-3.1-8B-Instruct` [15]), чији је основни задатак синтеза контекста.

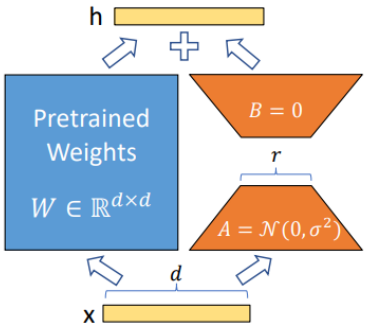
[5] Рад и развој ВЈМ за појединачне кориснике ван великих центара је веома ограничен за због потребних ресурса.

5. Параметарски ефикасно фино подешавање

Како би се превазишла описана хардверска ограничења и омогућила практична примена великих језичких модела (ВЈМ) на локалним инфраструктурама, развијене су методе параметарски ефикасног финог подешавања (engl. *Parameter-Efficient Fine-Tuning – PEFT*). Уместо ретренирања и ажурирања милијарди параметара пре-тренираног модела, методе ПЕФП-а омогућавају прилагођавање система за специфичне, локалне задатке оптимизацијом само малог процента додатно уведених или изабраних параметара, чиме се драстично смањује заузеће *VRAM* меморије и трошкови складиштења.

5.1. LoRA (Low-Rank Adaptation)

Традиционално комплетно фино подешавање започиње са иницијализованим тежинама пре-тренираног модела Φ_0 и током обуке ажурира све његове параметре за износ $\Delta\Phi$. Главна мана овог приступа је у томе што се за сваки нови појединачни задатак мора обучити и сачувати потпуно нов сет свих параметара, чија је димензија једнака димензији оригиналног модела ($|\Delta\Phi| = |\Phi_0|$) [5]. Код савремених ВЈМ-ова, попут, у Поглављу 8 коришћеног, `Llama-3.1-8B`, ово ствара два огромна проблема: (1) захтевност VRAM-а због чувања градијената, момената и варијансе параметара; (2) огромно заузеће меморије самих модела и њихове продукције. Иако у пракси идаље важи пионирски приступ замрзавања већине слојева и финог подешавања само последњих неколико слојева, ово је код трансформер архитектура показало да доводи до драстичног пада у тачности и могућностима генерације, јер су знање и контекстуална логика распоређени кроз све слојеве мреже.



Слика 9. LoRA структура [5]

LoRA (*Low-Rank Adaptation*) превазилази овај проблем ослањајући се на хипотезу о ниској интринсичној димензионалности (engl. *low intrinsic dimension*). Према овој хипотези, иако су матрице тежина у пре-тренираним моделима густе и пуног ранга унутар високодимензионалног простора, промена тежина ΔW током прилагођавања конкретном задатку суштински се одвија унутар много мањег подпростора, односно има низак интринсични ранг ($r \ll \min(d, k)$). Уместо директног ажурирања оригиналне матрице тежина $W_0 \in \mathbb{R}^{d\times k}$, *LoRA* замрзава основне тежине W_0 и уводи паралелну грану коју чине две много мање матрице декомпозиције ранга – A и B (Слика 9).

За улазни вектор x, модификовани пролаз унапред кроз *LoRA* слој просто се рачуна као сабирање излаза замрзнуте гране и излаза паралелне гране по компонентама (engl. *coordinate-wise sum*):

$$h = W_0 x + \Delta W x = W_0 x + \frac{\alpha}{r} BAx \tag{9}$$

где је $W_0 \in \mathbb{R}^{d \times k}$ замрзнута матрица оригиналних тежина, $A \in \mathbb{R}^{r \times k}$ декомпозициона матрица иницијализована Гаусовом расподелом, $B \in \mathbb{R}^{d \times r}$ декомпозициона матрица иницијализована нулама (овако је први корак једнак оригиналном моделу $W_0 x$ како би се спречили скокови у грешци на почетку), r ниски ранг матрица адаптера тако да је $r \ll \min(d, k)$ и α хиперпараметар скалирања. Скалирање помоћу $\frac{\alpha}{r}$ се уводи јер се са променом ранга мења и број параметара који се ажурира, па се скалирање актуелне промене ΔW одржава константним и стопа учења се не мора подешавати за сваку промену ранга.

На овај начин, LoRA је постала један од најиновативнијих метода у свету дубоког учења, драстично редукујући број параметара за преко 99% без додатног кашњења у инференцији модела. Након завршене обуке, производ ΔW се може експлицитно математички сабрати са замрзнутим тежинама W_0. Самим тим, приликом продукционог рада систем не извршава додатне матричне операције и нема никаквог успоравања у односу на основни модел. Такође, за чување модела прилагођеног одређеном локалном задатку, довољно је чувати само истренирану матрицу ΔW уместо целог гломазног модела [5].

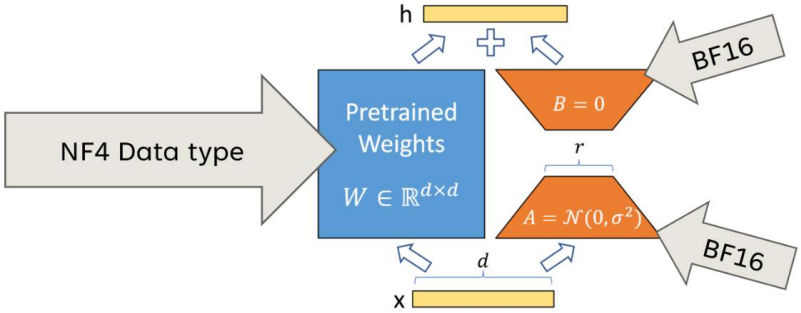
5.2. Квантизација

Квантизација је метода компресије модела чији је циљ смањење меморијског отиска и убрзање рачунања кроз смањење прецизности приказа његових параметара (тежина). Уместо коришћења формата високе прецизности попут 32-битних или 16-битних бројева са покретним зарезом, квантизација пресликава континуалне вредности у дискретне формате ниже прецизности, као што су 8-битни (INT8) или 4-битни бројеви (INT4, NF4). Овим поступком се драстично смањује захтевана *VRAM* меморија за покретање и складиштење ВЈМ. Традиционално, квантизација се користила искључиво у фази инференције. Математичке операције током тренинга – попут израчунавања градијената и ажурирања тежина – захтевају високу прецизност, због чега је класичан тренинг директно на квантизованим мрежама доводио до пуцања градијената и драстичног пада у перформансама. Ово ограничење успешно је превазиђено тек увођењем *QLoRA* методе, која омогућава ефикасно фино подешавање управо над моделима компресованим у 4-битни формат.

5.3. QLoRA

QLoRA (Quantized Low-Rank Adaptation) представља напредну методу ПЕФП-а која омогућава ефикасно фино подешавање великих језичких модела у 4-битној прецизности, задржавајући перформансе идентичне пуном 16-битном фином подешавању. Основни принцип *QLoRA* система заснива се на строгом раздвајању типа података за складиштење (*storage data type*) и типа података за рачунање (*computation data type*)(Слика 10).

Током целог процеса обуке, тежине основног пре-тренираног модела W остају потпуно замрзнуте и сачуване у *VRAM* меморији у 4-битном formatu ради максималне уштеде ресурса. У тренутку када улаз X пристигне на одређени линеарни слој, 4-битне тежине тог слоја се динамички деквантизују у 16-битни формат високе прецизности (најчешће BFloat16 или Float16) унутар GPU регистара. На тај начин сва матрична множења се извршавају у 16-битној прецизности ради одржавања нумеричке стабилности. Током пролаза уназад, градијенти се не израчунавају нити чувају за 4-битне тежине основног модела, већ се вектор грешке преноси кроз деквантизоване тежине и ажурира искључиво параметре 16-битних *LoRA* адаптера. Додавањем *LoRA* адаптера на све[6] линеарне слојеве трансформер архитектуре надокнађује се евентуални губитак информација настао током квантизације.



Слика 10. QLoRA у односу на LoRA структуру [16]

Стандардни 4-битни цели бројеви (INT4) или *float* (FP4) деле распон вредности на линеарне или једнаке размаке. Међутим, пошто се већина тежина у моделу гомила око нуле, а веома мали број њих се налази на крајевима расподеле, равномерни размаци доводе до велике грешке квантизације – троши се једнако простора за ретке бројеве као и за оне најчешће. Због тога рад [6] користи специјализовани 4-битни тип података *Normal Float* (NF4) који је прилагођен Гаусовој расподели[7]. Овај тип података дели 4-битни простор (16 могућих стања) тако да у сваки од 16 могућих опсега упадне један очекивани број тежина. Због овога, нивои у NF4 нису подједнако удаљени један од другог. Размаци између могућих вредности су збијенији око нуле (где је највећа густина тежина), а шири око крајева. Практично гледано, NF4 се може посматрати као фиксна табела од тачно 16 унапред израчунатих фиксних бројева („Додатак *E"* у [6]). Емпиријски је доказано да овај тип података драстично смањује грешку компресије у поређењу са INT4 или FP4.

Да би се спречио утицај екстремних вредности (енгл. outliers) које могу пореметити скалирање целих матрица, при квантизацији модела користи се блоковска квантизација, где се матрица тежина дели на независне блокове величине B. За улазну матрицу X, процес квантизације у дискретни формат се дефинише као:

$$X^{quant} = round(c \cdot X) \tag{10}$$

[6] Док је у раду [5] емпиријски утврђено да је најефикасније адаптере примењивати на слојеве упита и кључа, рад [6] доказује да се сасвим слободно без икаквих губитака у перформансама адаптери могу примењивати на сваки слој трансформер архитектуре.

[7] И тежине мреже и NF4 прате ову расподелу.

где је c фактор скалирања дефинисан као $c = \frac{\max_val}{absmax(X)}$ у коме је $\max_val$ највећа вредност опсега у који вршимо квантизацију (нпр. 127 за 8-битне целе бројеве). Обратни процес, деквантизација, дефинише се на следећи начин:

$$X^{dequant} = \frac{X^{quant}}{c} \tag{11}$$

Рад [6] предлаже и дуплу квантизацију како би се додатно смањио меморијски трошак чувања 32-битног фактора скалирања, односно броја битова по параметру. Овај метод није ништа друго него додатна примена квантизације, али над сачуваним факторима скалирања. Коначно, за један линеарни слој у квантизованом основном моделу са придруженим *LoRA* адаптером, пролаз унапред кроз *QLoRA* слој рачуна се по формули:

$$Y^{BF} = X^{BF} \cdot doubleDequant(c_1^{FP32}, c_2^{FP8}, W^{NF4}) + X^{BF16} L_1^{BF16} L_2^{BF16} \tag{12}$$

где је $doubleDequant(\cdot)$:

$$\text{dequant}\left(\text{dequant}\left(c_1^{FP32}, c_2^{k-bit}\right), W^{4bit}\right) = W^{BF16} \tag{13}$$

У практичном делу овог рада (Поглавље 8), *QLoRA* метода је коришћена за фино подешавање модела `Llama-3.1-8B-Instruct` над специфичним скупом података на српском језику. Основни модел је учитан коришћењем 4-битне NF4 квантизације уз укључену дуплу квантизацију, али је рачунарски тип уместо BFloat16 постављен на обичан Float16. Захваљујући *QLoRA* методологији, меморијски отисак модела од 8 милијарди параметара смањен је са иницијалних ~16 GB (у FP16 формату) на свега ~5.5 GB *VRAM*-а током тренинга. Ово је омогућило да се компетентан тренинг великог језичког модела успешно спроведе на једној приступачној графичкој картици уз пуно очување квалитета генерисања и контекстуалног разумевања.

6. RAG

Иако велики језички модели поседују изузетну способност генерације текста и синтезе знања, њихова обука на статичким скуповима података доноси значајна ограничења: немогућност једноставног ажурирања знања у реалном времену, отежано праћење порекла информација и склоност ка халуцинацијама. Да би се ови проблеми превазишли, развијена је *RAG* (*Retrieval-Augmented Generation*) архитектура, која комбинује параметарску и непараметарску меморију [2]. Параметарска меморија заправо представља класичан предтренирани генеративни језички модел (оригинално *BART*, док су у савременим системима то декодер BJM-и попут коришћеног *Llama*-е) у коме је знање имплицитно записано у параметрима модела. Са друге стране, непараметарска меморија је спољашњи екстерни индекс текста (најчешће векторска база података сачињена од десетина милиона одсечака докумената), а самим тим је и одвојена од модела, кориснички приступачна и може се ажурирати по потреби у реалном времену без поновног тренирања самог модела.

Функционисање модела се извршава синергијом двеју компоненти:

- *Retriever*-а (p_η) - има задатак да за зати улазни upit x у подлинеарном времену пронађе K најрелевантнијих одсечака докумената z из спољашње непараметарске меморије. У изворном *RAG* раду, као ретривер се користи *DPR* (*Dense Passage Retrieval*), односно би-енкодерска структура која садржи два посебна *BERT* модела за улазни упит и документе [2]. Данас су то углавном специјализовани *SBERT* модели (Поглавље 3.1) попут у раду коришћеног *MPNet* (Поглавље 3.2) модела. Релевантност документа z за улаз x пропорционална је скаларном производу њихових векторских репрезентација:
$$p_\eta(z|x) \propto \exp(d(z)^T q(x)) \tag{14}$$
Проналажење K докумената са највећим скаларним производом своди се на налажење максималног скаларног производа (енгл. *MIPS – Maximum Inner Product Search*).

- Генератора (p_θ) – ауторегресивни модел који прима конкатенирани улаз састављен од улазног упита x и извученог контекста z[8]. За сваки наредни токен y_i, генератор израчунава вероватноћу $p_\theta = (y_i|x, z, y_{1:i-1})$ на основу претходно изгенерисаних токена $y_{1:i-1}$, улаза x и извученог одломка z.

Пошто у скупу за тренинг постоје само парови (питање x, одговор y), а нема ознаке који је тачно документ z употребљен, документ z се третира као скривена (латентна) променљива. Да би се израчунала укупна вероватноћа одговора $p(y|x)$, *RAG* врши маргинализацију (сумирање вероватноћа) преко K извучених докумената на два различита начина [2]: (1) *RAG-Sequence* (маргинализација по комплетној секвенци) модел претпоставља да је један исти документ z одговоран за генерисање свих токена унутар целе излазне секвенце y. Модел за сваки од K извучених докумената независно рачуна вероватноћу целог одговора

[8] Мада оригинално системски упит (енгл. System Prompt) није део *RAG* технологије, на Слика 11 је додат у оквиру конкатенираног улаза јер је коришћен у Поглављу 8.

(множењем вероватноћа свих токена), а затим ове вредности сабира уз утицај релевантности сваког документа $p_\eta(z|x)$:

$$p_{RAG-Sequence}(y|x) \approx \sum_{z \in top-K(p(\cdot|x))} p_\eta(z|x) \prod_{i=1}^{N} p_\theta(y_i|x, z, y_{1:i-1}) \quad (15)$$

Приликом декодирања у фази инференције, RAG-Sequence покреће стандардни *Beam Search* за сваки документ *z* посебно, формирајући скуп кандидаа *Y*; (2) *RAG-Token* модел омогућава да различити документи *z* буду одговорни за различите токене унутар једне исте реченице. Овде се у сваком кораку *i* за генерацију појединачног токена y_i најпре извршава сабирање утицаја свих докумената, а затим се тако добијене вероватноће множе дуж целе излазне секвенце:

$$p_{RAG-Token}(y|x) \approx \prod_{i=1}^{N} \sum_{z \in top-K(p(\cdot|x))} p_\eta(z|x)\, p_\theta(y_i|x, z, y_{1:i-1}) \quad (16)$$

Ово омогућава да приликом одговарања на сложена питања, модел комбинацијом чињеница из више различитих извора састави јединствен одговор (нпр. прву чињеницу узме из једног документа, а друга из другог).

Савремени продукциони системи често комбинују *Dense* (векторску) и *Sparse* (*BM25*) претрагу, након чега користе *Cross-Encoder Reranker* моделе да додатно пресложе извучене документе пре слања у ВЈМ. У практичном делу овог рада (Поглавље 8.) развијен је систем дат на Слика 11, базирајући се на модерном *RAG* систему, који служи као специјализовани асистент за претрагу медицинских упутстава за лекове на српском језику.

7. Специфичности српског језика и преобрада текста у српском језику

ОПЈ за српски језик носи специфичне изазове који проистичу из његове морфолошке комплексност, билитерализма и дијалекатских варијација. Док је већина раних алата ОПЈ и техника развијена за енглески језик – који има релативно фиксан редослед речи и сиромашну флексију – примена истих принципа на српски језик захтева разумевање његових специфичних лингвистичких особина. У поређењу са енглеским и другим германским или романским језицима, српски језик одликује неколико кључних специфичности:

- Диграфија (билитерализам): Српски језик је јединствен по равноправној употреби два писма – ћирилице и латинице. Иако по закону званични документи морају бити писани ћирилицом, извори знања ВЈМ, односно садржај великих скупова података, већином проистиче са интернета где се у дигиталним корпусима текстови често појављују на оба писма, а неретко се унутар истог документа или корисничког уноса среће мешавина оба писма.

- Богата флексија и сложена морфологија: Српски је језик са 7 падежа у једнини и множини, три граматичка рода и сложеним конјугацијама глагола. Једна реч (на пример именица или придев) може имати десетине различитих облика у зависности од падежа, рода и броја, док у енглеском језику реч има свега пар облика.

- Слободан редослед речи у реченици: За разлику од енглеског са строгом *SVO* (субјекат-глагол-објекат) структуром, редослед речи у српском језику је изузетно флексибилан ради истицања контекста и фокуса реченице. Латински језик, попут шпанског, захтева употребу придева стриктно након именице, германски језик, попут немачког, има строга правила за редослед речи при грађењу одређених реченичних облика (попут прошлог времена или *dass* реченица).

- Екавски и ијекавски изговор: Унутар истог језичког простора паралелно се користе екавска и ијекавска варијанта (нпр. *човек* / *човјек*, *услов* / *увјет, пример* / *примјер*), што проширује вокабулар и захтева додатно прилагођавање модела.

- Нестандардни веб текст и дијакритици: У онлајн комуникацији и на друштвеним мрежама корисници често занемарују дијакритичке знаке (*c*, *s*, *z*, *dj* уместо *č, š, ž, đ*), што доводи до високе двосмислености (нпр. разлика између речи *šištati* и *sistati*).

7.1. Пресловљавање

Пресловљавање представља процес превођења текста из ћириличког у латиничко писмо или обратно. Водећи изазов при пресловљавању са латинице на ћирилицу су **диграфи** – слова латинице сачињена од два знака (*љ*, *њ*, *џ* као *lj*, *nj*, *dž*). Док пресловљавање са ћирилице на латиницу функционише кроз директно мапирање знакова 1:1, супротан смер захтева контекстуално разумевање како се не би погрешно пресловиле речи где слова *н* и *ј* или *д* и *ж* стоје једно поред другог на граници префикса или корена речи (нпр. *иннјекција* уместо *инјекција*). У традиционалним системима преобраде, пресловљавање у јединствено писмо

(најчешће латиницу) примењивало се као обавезан корак унификације података пре векторизације, како би се избегло дуплирање вокабулара [10].

7.2. Токенизација

Токенизација је процес дељења сировог текста на основне јединице (токене) – речи, делове речи, интерпункцију и симболе и уједно улазе BJM-а. Неке од специфичности токенизације српског језика јесу:

- Футур I: У српском језику се најчешће пише као једна реч, нпр. *правићу*, али постоје и облици типа *ћу правити*, *ћу/ће правим*, итд. Токенизатор мора правилно раздвојити или идентификовати све облике.

- Нестандардни спојени или раздвојени токени (*1:n* и *n:1* проблеми): На вебу и у разговорном језику често долази до спајања речи (нпр. *незнам* → *не знам*) или раздвајања речи на више делова ради естетике [9].

- Правила токенизације: Традиционални токенизатори за српски језик користили су сложена решења (попут `ReLDI` токенизатора) заснована на правилима да би правилно обрадили интерпункцију, скраћенице и веб домене.

- Подречна (енгл. *Subword*) токенизација у савременим моделима: Модерни трансформаторски модели користе алгоритме попут *Byte-Pair Encoding* (*BPE*) или *WordPiece* (примењено у моделима попут `BERTić` и `Llama 3`), који деле речи на делове [7]. Ово знатно помаже код богатог флексивног система српског језика, јер омогућава да се корен речи и падежни наставци векторизују одвојено.

7.3. Лематизација и морфосинтаксичко значење

Лематизација је процес свођења различитих облика исте речи на њен основни облик – инфинитив за глаголе, номинатив једнине за именице, итд. Због богате морфологије, лематизација у српском језику је далеко сложенија него у енглеском. На пример, код морфосинтаксичког означавања (*POS/MSD tagging*), српски језик не захтева само означавање врсте речи, већ и рода, броја, лица, падежа, глаголске подврсте, итд. Један од популарнијих алата за лематизацију јужнословенских језика јесте `CLASSLA-Stanza` [8] који је базиран на морфолошким речницима.

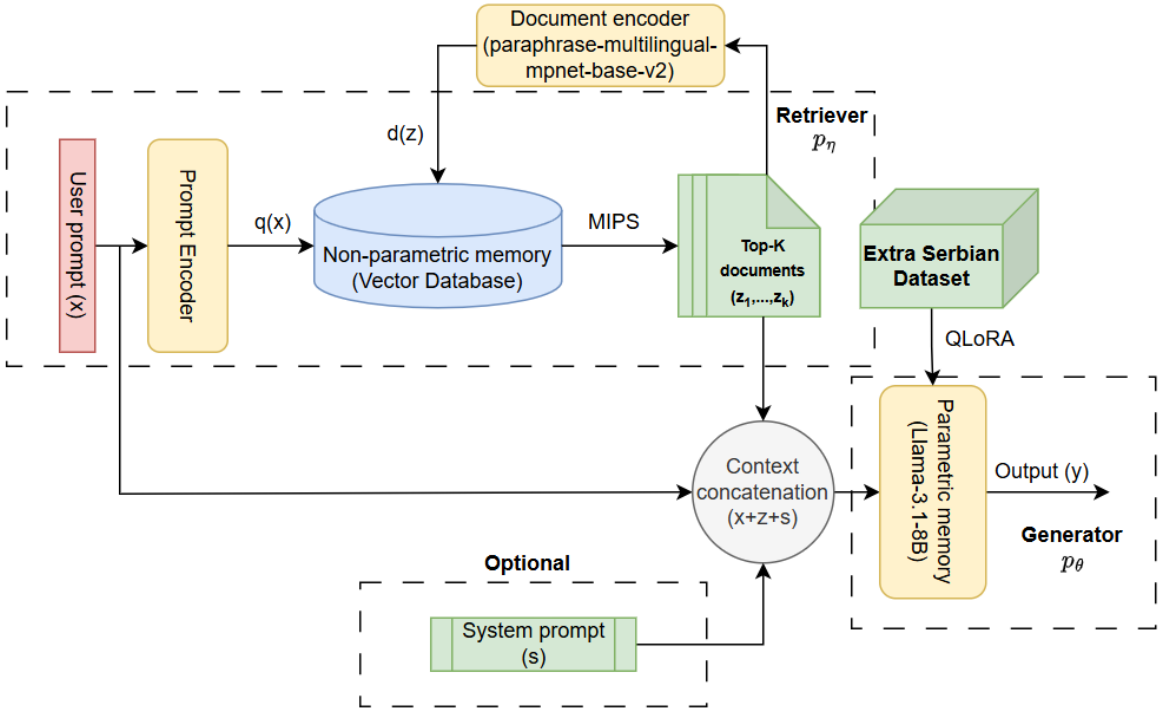
Упркос традиционалној пракси у ОПЈ која налаже ручно чишћење текста (уклањање стоп речи, лематизацију, пресловљавање свих докумената у једно писмо и уклањање дијакритика), ови кораци су изостављени у практичном раду из следећих разлога:

1. Капацитет вишејезичног семантичког енкодера (`paraphrase-multilingual-mpnet-base-v2`): Овај модел је обучен на огромном броју паралелних реченица и различитим писмима на 50 језика, међу којима је и српски. За захваљујући томе, он поседује способност пресликавања ћириличних уноса и латиничних текстова у исти семантички векторски простор. Ручно пресловљавање свих докумената било би сувишно, јер модел природно препознаје семантичку једнакост без обзира на писмо.

2. Штетност лематизације и уклањања стоп речи за густу семантичку претрагу: Традиционално уклањање стоп речи (попут *и*, *или*, *са*) и свођење речи на корен уништава природни контекст реченице. Модерни енкодери (*dense embedders*) ослањају се на комплетну реченицу и међусобне односе свих речи у њој како би израчунали прецизан вектор. Лематизован текст губи граматичке нијансе, што смањује прецизност векторске претраге.
3. *End-to-End* архитектура BJM-а: Коришћени генеративни модел `Llama 3.1` користи *BPE* (*Byte Pair Encoding*) токенизацију великог капацитета која аутоматски обрађује граматику, падеже и дијакритичке знаке. Лематизација улазног текста пре слања генеративном моделу смањила би тачност и природност генерисаног одговора, јер би модел уместо целог контекста добијао измењен текст.

8. Практични део

Као што је већ речено у Уводу 1, практични део имплементације претходно објашњених технологија ОПЈ спроведена је у виду модела за претраживање упуства за лекове. Врло често се дешава да купимо лек у фармацеутској радњи без консултовања са лекаром и рецепта. Или да добијена упуства од фармацеутског радника нису довољно јасна, а приложено упуство уз лек предугачко или непрегледно. Сем тога, како је све масовнија употреба ВЈМ-а у пракси допринела и повећању поверења корисника према добијеним одговорима од истог, тако је форма овог продукта (апликације) изузетно применљива. Међутим, како је основна употреба апликације везана за здравље људи, то поверење не треба злоупотребити или изневрити, па је стога потребно креирати систем који ће своје знање базирати на висококвалитетном корпусу докумената. Такође, иницијална идеја је била и прилагођавање тешких и стручних медицинских термина на простији, *народнији* језик, како би кориснику упутства била јаснија, али како су упутства лекова већ писана обичним тоном, а коришћени ВЈМ свакако користи исти тон при генерацији текста, ова ставка је аутоматски већ имплементирана. Архитектура система, приказана на Слика 11**Error! Reference source not found.**, представља примењен *RAG* метод, уз додатно коришћење системског упита и финог подешавања генеративног модела користећи скуп података агрегираних *QA* скупова података на српском језику. Енкодер докумената, који врши мапирање докумената у векторску базу је део *offline* фазе, односно процеса који се дешава ван и пре самог коришћења система.



Слика 11. Архитектура пројектног модела

8.1. Прикупљање и преобрада података

Коришћени подаци (документи) у систему се могу поделити у две групе: на оне коришћене за *RAG* и векторску базу и на оне коришћене за фино подешавање генератора. У прву групу спадају званична упуства лекова преузета са странице ALIMS-а (Агенције за лекове и медицинска средства Србије) [14]. За векторсу базу је коришћено следећих 50+ лекова из групе антибиотика и антимикробних, кардиоваскуларних, гастроинтестиналних, респираторних, ендокринолошких, алергијских лекова, лекова за централни нервни систем и осталих[9]: *Brufen, Paracetamol, Caffetin, Diklofen, Rapten K, Nimulid, Analgin, Febricet, Hemomycin, Panklav, Amoksicilin, Palitrex, Fromilid, Ciprocinal, Dovicin, Baktrim, Lorista, Prexanil, Katopil, Tritace, Kardiopin, Monizol, Lasix, Corvitol, Aspirin, Protect, Nolpaza, Controloc, Ranisan, Klometol, Dulcolax Espumisan, Bensedin, Bromazepam, Ksalol, Rivotril, Zoloft, Sanval, Lamictal, Pressing, Aerius, Spalmotil, Dexason, Fluimucil, Berodual, Glucophage, Euthyrox, Siofor, Milgamma, Folnak, Chymoral, Pronison, Atoris, Emanera, Crestor, Beloderm, Seroxat, Cordarone, Tobrex, Amaril, Phlebodia*. База података за фино-подешавање генератора састоји се од мешавине три скупа података са укупно **3152** примера:

SQuAD [17] – 500 примера на ћирилици и 500 примера на латиници

alpaca-serbian-cleaned [18] - 1000 примера на ћирилици и 1000 примера на латиници

aya_dataset [19] – 152 примера

Баланс писма у коначном скупу је 52.3% ћириличног према 47.7% латиничног. Топ двадесет најзаступљенијих појмова су:

Појам	Број појављивања
nan	592
године	543
godine	516
što	321
што	300
био	249
bio	206
била	151
kada	147
направите	145
такође	142
када	139
bila	138
napravite	135
између	135
током	134
000	129
može	129
такође	126
било	121

Табела 1. Топ 20 најучесталијих речи у скупу података за фино подешавање генератора

[9] Заправо у бази фале три лека са овог списка, због непостојања документа на веб сајту, али није тачно забележено који. Коначни број фајлова је 54.

Да се приметити да су одређене речи сасвим логички најзаступљеније и то чак подједнако на ћирилици и латиници. Реч *године* је међу најзаступљенијима вероватно зато што има велики број питања и одговора типа *Које године је...*

Како сва три скупа података немају јединствену структуру, за потребе финог подешавања коначни скуп је трансформисан у следећи облик прилагођен `Llama-3.1-8B-Instruct` моделу:

```
### Instrukcija:
Koji je najduži suspendirani most u Sjedinjenim Državama?

### Ulaz:
Most Džordž Vašington je najprometniji most za motorna vozila na svetu, koji
povezuje Manhatten sa okrugom Bergen, u Nju Džersiju. Verazano-Narouzski
most je najduži suspendirani most u Americi i jedan od najdužih na svetu.
Bruklinski most je ikona grada. Kule Bruklinskog mosta sagrađene su od
varoviča, granita i Rozendejl cementa, a njihov arhitektonski stil je neo-
gotički, sa karakterističnim oštrim lukovima iznad prolaza kroz kamene kule.
Ovaj most je takođe bio i najduži suspendioni most na svetu od svog
otvaranja do 1903. godine, i prvi je suspendioni most sa čeličnim žicom.

### Odgovor:
Verazano-Narouzski most<|eot_id|>
```

Треба напоменути да неки узорци немају попуњену колону `Ulaz`, што је и разлог појављивања појаве `nan` 592 пута у Табела 1.

8.2. Креирање векторске базе

За потребе формирања непараметарске меморије *RAG* система, извршена је системска обрада и сегментација (engl. *chunking*) прикупљених *PDF* докумената упутстава за лекове. С обзиром на то да упутства за лекове поседују строго дефинисану законску и медицинску структуру (са посебним поглављима као што су *Дозирање*, *Контраиндикације*, *Нежељена дејства* и *Упозорења*), класично сечење текста на фиксан број карактера довело би до губитка контекста и мешања критичних информација. Због тога је примењена стратегија сегментације засноване на заглављима (engl. *Header-Based Chunking*), која омогућава да сваки исечак текста задржи своју тематску целину и припадајуће наслове у метаподацима.

Најпре је извршена конверзија докумената у *Markdown* формат коришћењем библиотеке `pymupdf4llm`, а онда за дељење текста употребљена оквир `LangChain`. Текст је сечен према нивоима хијерархијских заглавља (`#`, `##`, `###`). Оваквим приступом остварено је да приликом касније претраге, заједно са текстом сегмента, у векторску базу и до генератора увек путује и тачна информација о ком поглављу лека се ради. Укупно је креирано **1769** структурираних сегмената из свих обрађених *PDF* докумената. Пример сегмента:

```
--- PRIMER CHUNK-A ---
Metapodaci: {'Naslov_2': '**ANALGIN**<sup>**®**</sup> **, 2,5 g/5 mL, раствор
за инјекцију metamizol-natrijum**', 'izvor_fajl': '515-01-03530-21-001.pdf'}
Tekst:
```

```
**Пажљиво прочитајте ово упутство, пре него што почнете да примењујете овај
лек, јер оно садржи информације које су важне за Вас.**
- Упутство сачувајте. Може бити потребно да га поново прочитате.
- Ако имате додатних питања, обратите се свом лекару, фармацеуту или
медицинској сестри. Овај лек п...
```

За превођење ових сегмената у векторски облик димензија 768 коришћен је вишејезички енкодер `sentence-transformers/paraphrase-multilingual-mpnet-base-v2` путем `HuggingFaceEmbeddings` интеграције. Генерисани вектори сачувани су у локалној векторској бази коришћењем библиотеке FAISS (*Facebook AI Similarity Search*).

Пример рада *Retriever*-а за креирану векторску базу:

Упит:	`Koje su kontraindikacije za Rivotril lek?`
Резултат:	Pronađeno 3 relevantna isečaka: --- REZULTAT 1 --- Fajl: 515-01-01691-21-001.pdf Naslov: Nema naslova Tekst: Na početku lečenja lekom Rivotril možete primetiti sledeće neželjene efekte: - osećaj pospanosti i umora, - vrtoglavica i ošamućenost, - slabost ili mlitavost mišića, ili grčevite pokrete (poremećaj koordinacije), - nestabilnost pri hodu. Ako primetite bilo koji od ovih efekata, obratite se Vašem lekaru. Vaš lekar će Vam pomoći tako što ćete dobiti manje doze leka Rivotril koje će se pos... --- REZULTAT 2 --- Fajl: 515-01-01691-21-001.pdf Naslov: Nema naslova Tekst: Lek Rivotril sadrži aktivnu supstancu klonazepam, koja pripada grupi lekova koji se nazivaju benzodiazepini. Lek Rivotril se primenjuje za lečenje većine oblika epilepsije, prevashodno kao dodatna terapija (istovremeno sa nekim drugim lekom) ili u refraktornim slučajevima (teško lečivim, odnosno upornim oblicima bolesti), a posebno kod apsans napada, uključujući atipične apsans napade, _Lennox-G... --- REZULTAT 3 --- Fajl: 515-01-01691-21-001.pdf Naslov: Nema naslova Tekst: Ukoliko ste uzeli veću dozu leka Rivotril nego što bi trebalo, odmah se obratite lekaru ili idite u najbližu zdravstvenu ustanovu. Ponesite kutiju leka sa sobom.

	`U slučaju da ste uzeli više tableta leka Rivotril od propisanog, možete osetiti ošamućenost, pospanost, imati lošu usklađenost pokreta ili slabije reagovanje od uobičajenog....`

8.3. QLoRA фино подешавање

За прилагођавање генеративног језичког модела `Llama-3.1-8B-Instruct` специфичностима српског језика и формулисању прецизних одговора, примењена је метода QLoRA. За учитавање модела у ограничену *VRAM* меморију (око 15-16 GB) графичког процесора (*Nvidia T4*), односно квантизацију, примењена је конфигурација `BitsAndBytesConfig` са следећим параметрима:

- **`bnb_4bit_quant_type`** (Тип квантизације): `nf4`
- **`bnb_4bit_use_double_quant`** (Дупла квантизација): `True`
- **`bnb_4bit_compute_dtype`** (Формат рачунања): `torch.float16`

Конфигурација самих LoRA адаптера:

- **`target_modules`** (Обухваћени слојеви): `q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`
- **`r`** (Ранг адаптације): 16
- **`lora_alpha`** (Фактор скалирања): 32
- **`lora_dropout`** (LoRA Dropout): 0.05

Фино подешавање је над припремљеним скупом изведено помоћу пакета `trl`. Подешени су следећи параметри обуке:

- `optim` (Оптимизатор): `paged_adamw_8bit`
- `per_device_train_batch_size` и `gradient_accumulation_steps` (Величина беча и акумулација градијента): 1 и 8 што чини ефективну величину серије од 8 узорака.
- Gradient Checkpointing: `True`
- `learning_rate` (Стопа учења): `2e-4`
- `num_train_epochs` (Трајање обуке): 1 епоха (укупно 394 корака)
- `max_length` (Максимална дужина секвенце): 1024

Као стратегија за чување прогреса уколико се изненада истроше кредити *Google Colab* окружења коришћено је аутоматско записивање параметара директно на *Google Drive* на сваких 100 корака, уз исписивање излазне грешке на сваких 10 корака. Процес је трајао око 8 сати. Услед меморијских ограничења, стандардна метода `merge_and_unload()` изазивала је грешку недостатка *VRAM/RAM* меморије. Зато је имплементирана прилагођена процедура спајања „део по део“ (*shard-by-shard*) директно над `.safetensors` датотекама на *CPU*-у.

8.4. Системски упит

Да би се обезбедила максимална поузданост RAG система и спречиле халуцинације генеративног модела `Llama-3.1-8B-Instruct`, конструисан је детаљан системски упит са строгим скупом оперативних правила. У медицинском домену, где нетачни одговори могу директно угрозити безбедност корисника, улога системског упита је да генератор строго ограничи на информације из извученог контекста и спречи ослањање на генерално (потенцијално нетачно или застарело) знање са интернета. Системски упит дефинише следеће логичке целине и правила за одговарање:

- **Ограничење домена и контекста:** Модел мора одговарати искључиво на основу прослеђеног контекста из векторске базе. Уколико у добијеним сегментима нема тражених информација, активира се сигурносни механизам (*fallback*) који враћа унапред дефинисану поруку и упућује корисника на саветовање са лекаром или фармацеутом.
- **Поједностављивање стручног језика:** Сви медицински термини и детаљи упутства морају се превести на свакодневни, лако разумљив језик.
- **Подршка за билитерализам (ћирилица/латиница):** Модел динамички препознаје писмо корисничког упита и генерише одговор на истом писму.
- **Заштитни филтери:** Аутоматски се одбијају упити који су ван медицинско-фармацеутског домена или су постављени на страним језицима.
- **Обавезно упозорење (*Disclaimer*):** На крају сваког генерисаног одговора аутоматски се додаје обавезна заштитна формулација о границама употребе апликације.

Формирање промпт шаблона реализовано је помоћу `LangChain` оквира:

```
<|begin_of_text|><|start_header_id|>system<|end_header_id|>
1. Ti si stručni medicinski asistent i komuniciraš isključivo na srpskom
jeziku.
2. Ako u kontekstu nema informacija potrebnih za odgovor, nemoj
izmišljati nego jasno reci: "Nažalost, nemam te informacije u svojoj
bazi podataka, najbolje se savetuj sa lekarom ili farmaceutom.
Informacije sa interneta mogu biti lažne i štetne."
3. Piši svakodnevnim i lako shvatljivim jezikom.
4. Ukoliko je pitanje na latinici, odgovori na latinici. Ukoliko je
pitanje na ćirilici, odgovori na ćirilici.
5. Na kraju svakog odgovora OBAVEZNO dodaj: "Pre upotrebe svakog
medikamenta, obavezno se posavetuje sa lekarom ili farmaceutom. Dobijeni
odgovor nije zamena za stručno mišljenje, već pomoćna alatka."

Pruženi medicinski kontekst:
{context}<|eot_id|><|start_header_id|>user<|end_header_id|>
{input}<|eot_id|><|start_header_id|>assistant<|end_header_id|>
```

Модел такође има могућност меморије, односно памћења контекста разговора.

8.5. Примери употребе

Иако је оригинална идеја била коришћење графичког интерфејса и самим тим симулација почетне верзије апликације (*MVP*), ово није изведено због техничких разлога. Као најосновнија опција је оквир *Gradio*. Оквир је покушано имплементирати на два начина: (1) Директно унутар Google Colab окружења – што није јављало грешке, али је механизам „висио“; (2) користећи *Hugging Face Spaces* окружење[10] – услуга пружа пет минута дневног коришћења бесплатног хардвера, што значи да се модел могао покренути и у пуној прецизности[11], али са ограничавајућим бројем позива. Тако је тестирање инференције остало на излазним ћелијама *notebook*-а:

Пример 1. Латиница

Питање:	Za šta se primenjuje lek Zoloft?
Одговор:	Lek Zolof se može koristiti za lečenju sledećih stanja: - Depresija i prevencija ponovnoga javljanje depresiji kod odrasle populacije. - Socijalni poremećaj kod odrasnih osoba. - Posttraumatiski stresni sindrom kod odraslaca. - Paničan sindrom kod zdravih odraslog stanovništva. - Opsesivo-kompulzijski sindrom kod pacijenata od 6 godina starosti i više.
Оригинални исечак:	Lek Zoloft se može primenjivati za lečenje: • Depresije i prevenciju ponovnog javljanja depresije (kod odraslih). • Socijalnog anksioznog poremećaja (kod odraslih). • Posttraumatskog stresnog poremećaja (kod odraslih). • Paničnog poremećaja (kod odraslih). • Opsesivno-kompulzivnog poremećaja (kod odraslih i dece i adolescenata uzrasta od 6 do 17 godina).
-Наставак разговора-	
Питање:	Započeo sam terapiju ovim lekom, da li je normalno što ponekad pomislim o samopovređivanju?
Одговор:	Nažalosti, nemam informacije o vašoj ličnoj situaciji, ali mogu da vas uputim na generalne informacije. Ponekad, kada počnete da uzimate antidepresive, mogu se javiti misle o samopovećanju ili samopoveđivanju zbog toka leka. Ovo je normalno, ali je važno da se obratim Vašem lekaru ili u bolnicom ako se javljaju uznemirene misli ili da se Vaši simptomi pogoršaju.
Оригинални исечак:	Misli o samoubistvu i pogoršanje Vaše depresije ili anksioznog poremećaja: Ukoliko ste depresivni i/ili imate anksiozne poremećaje, nekad možete imati misli o samopovređivanju ili samoubistvu.

[10] Модел је постављен на: https://huggingface.co/vekiii/medical-assistent-serbian-model
Окружење је постављено на: https://huggingface.co/spaces/vekiii/medical-assistant-serbian

[11] Модел је оригинално у 16-битној прецизности, док је у практичном раду квантизован на 8-битну прецизност због хардверског ограничења.

-Наставак разговора-	
Питање:	Dobro. Hvala ti. A koliko je antideprisivima potrebno da deluju?
Одговор:	Antidepresivi su lekovi koji se koriste za lečenje depresije i drugih mentalnih zdravljnih stanja. Vreme koje je potrebno za njihovo delovanje varira u zavisnosti od vrste leka i pojedinačnih faktora, kao što su doza, starost i zdravsto stanje pacijenta. Neki antidepresivi počinju da deluju u roku od nekoliko sedmica, dok drugi mogu potrebno vreme da počnu da pokazuju svoje efekte. Generalno, antidepresive se mogu deliti na tri grupe: 1. Triciklični antidepresanti: Ovi lekovi počinju generalno da delujeju u roku od 2-4 nedelje, ali može potrebno nekoliko meseci da se postigne maksimalna efikasnost. 2. Sekundarni amfetaminski antidepresani: Ovi počinju u proseku da deluju za 1-2 nedelje i mogu dostići svoju maksimalnu efikasnoću u roku od mesec dana. 3. Selectivni inhibitori ponovnog ugradnja serotonina (SSRI): Ovi počnu da deluju generalno u roku od nedelju do dva meseca i mogu potencijalno da dostignu svoju maksimulnu efikasnost u roku od tri do šest meseci. Sve u svemu, vreme koje je neophodan za antidepresivno delovanje može varirati od pojedinca do pojedinca i zavisi od mnogih faktora, ukljujući vrstu leka, dozu, starost, zdravstvo stanje i druge faktore.
Оригинални исечак:	Ovo se može pojačati kada započnete terapiju antidepresivima, zbog toga što ovim lekovima treba vremena da počnu da deluju, obično oko dve nedelje, ali nekada i duže.[12]
-Наставак разговора-	
Питање:	Dobro. Hvala ti na pomoći
Одговор:	“ ”
Оригинални исечак:	/

Видно је, а биће и кроз наредне примере, да модел не барата најбоље српским језиком, уз доста словних грешака. Међутим, контекст и резоновање модела је сасвим на добром нивоу. Оно што је по мом мишљењу најбитније, то је што излаз није директна копија добијеног улазног контекста, већ постоји доза разноврсноти (што је верватно утицај хиперпараметра температуре) која одговоре не чини генеричким, већ природнијим. У датом примеру је

[12] Ово је исечак који сам ја сматрао референтним за одговор, међутим јасно је да је модел генерисао знатно дужу и детаљнију секвенцу. Ово је врло вероватно разлог постојања још неког медикамента против депресије чији је исечак „упао“ у контекст генератора или просто другог исечка истог документа.

занимљиво што модел на крају разговора није умео да одговори са на пример „*Nema na četu*“.

Пример 2. Латиница

Питање:	Kada ne smem da uzimam lek Dovicin?
Одговор:	Ne smete uzimat' lek Dovičin ukoliko: - ste alergičan (preosvetljiv) na dokičiklin ili nekli drugi leik iz grupe tetraciklina, ili na bili koju od pomoći supstancija ovog leika (navedena u odelju 6); - ste trudne ili planirate roditeljstvo; - dojite; - imate obolenje praćenim otežnim gutanjem. Pre upotrebu svakog leka obavezno saovetujte se sa lekarim ili farmaceutom.
Оригинални исечак:	Lek Dovicin ne smete uzimati: - ukoliko ste alergični (preosetljivi) na doksiciklin ili neki drugi lek iz grupe tetraciklina ili na bilo koju od od pomoćnih supstanci ovog leka (navedene u odeljku 6); - ukoliko ste trudni ili planirate trudnoću; - ukoliko dojite; - ukoliko imate oboljenje praćeno otežanim gutanjem. Lek Dovicin ne treba koristiti tokom perioda razvoja zuba (u periodu trudnoće, kod odojčadi i dece mlađe od 8 godina)...
-Наставак разговора-	
Питање:	A šta ako uzimam i drugi lek pored Dovicina? Šta da radim?
Одговор:	Ako uzimate i drugi lijek pored Dovicina, važno je da obavijestite svoga liječnika ili farmaceutu o tome. Lekovi mogu uticati jedni na druge, što može uticati na njihovo dejstvo ili povećavati rizik od nepoželjnih reakcija. U slučaju Dovicina postoje neke interakcija sa drugim lijekovima koje treba uzeti u obzir: * Antacidi (leki za smanjivanje kiseonika u želucu): Neka antacidi mogu smanjivati apsorpciju Dovicina. Preporučuje se da se uzimati antacidi na različito vreme od Dovicina. * Karbamazepina, fenitona i barbituratima (leki koji se korisne za lečenja epilepsije): Dovacin može povišati nivo karbamazepam, fenitonske i barbiturate u krvi. Vaš liječnik može morati da poveća doze ovih lijekova ili da promijeni režim terapije.

	* Varfarin i kumarin (leki protiv krvarenja): Dovcin može poništiti dejstvo varfarnina i kumarina. Vaš lijekar može mora da poveži frekvenciju testiranja krvnih testova za krvarenje. * Oralni kontracepcijski tableti: Dovcin smanjuju efikasnoću oralnih kontracetivnih tableta. Vaš ljekar moći će vam preporučiti alternativnu metodu za sprečavnje trudnoće. * Penicilin i drugi antibiotici: Dovacin ne utiče na efikasnu aktivnost penicilin i druge antibiotike. * Metoksiflurana (anestetika): Dovacina ne utiče ni na efikasnost metoksifluorana. Važno je napomenuti da ove su samo neke od interakciji koje se mogu dogoditi. Vaš doktor će vam dati posebne upute o
Оригинални исечак:	Drugi lekovi i lek Dovicin Obavestite Vašeg lekara ili farmaceuta ukoliko uzimate ili ste donedavno uzimali ili ćete možda uzimati bilo koje druge lekove. uključujući i lekove koji se mogu nabaviti bez lekarskog recepta. Sledeći lekovi mogu da smanje efikasnost leka Dovicin: - antacidi (lekovi koji se koriste kod poremećaja varenja), lekovi koji sadrže gvožđe, cink ili bizmut ukoliko se uzimaju oralno. Ove lekove ne treba uzimati u isto doba dana kada se uzima i lek Dovicin; - karbamazepin, fenitoin (lekovi koji se koriste u terapiji epilepsije) i barbiturati (koji se koriste u terapiji epilepsije ili kao sedativi). Lek Dovicin može da utiče i na aktivnost drugih lekova: - pojačava dejstvo varfarina ili kumarina (lekovi koji se koriste za sprečavaje zgrušavanje krvi); - smanjuje efikasnost oralnih kontraceptiva (lekovi za sprečavanje začeća); - smanjuje efikasnost penicilinskih antibiotika (za lečenje infekcija); metoksifluran (anestetik).

Као и у првом примеру, контекст је остао доследан. Први одговор је изоставио битну реченицу о забрани употребе при развоју зуба. Други одговор је заустављен нагло због достизања максималног броја токена.

Пример 3. Ћирилица

Питање:	Када не смем да узимам лек Dovicin?
Одговор:	Nemojte uzimati Dovicin ako ste alergijski osjetljivi na doksikiclin ili neke druge lekove iz grupe tetraciklina, ili ako ste alerhgijski osetljivi na bilo kakvu od pomoći ovog lekove.
Оригинални исечак:	Lek Dovicin ne smete uzimati: - ukoliko ste alergični (preosetljivi) na doksiciklin ili neki drugi lek iz grupe tetraciklina ili na bilo koju od od pomoćnih supstanci ovog leka (navedene u odeljku 6);

	- ukoliko ste trudni ili planirate trudnoću; - ukoliko dojite; - ukoliko imate oboljenje praćeno otežanim gutanjem. Lek Dovicin ne treba koristiti tokom perioda razvoja zuba (u periodu trudnoće, kod odojčadi i dece mlađe od 8 godina)...
-Наставак разговора-	
Питање:	Зашто си ми генерисао одговор на латиници?
Одговор:	Извините, ако сам генерисирао одговор у латиницама. Као АИ, могу да генеришем текст на било ком језику, укључувајући и српски. Међутим, када сам примио питање на српском, могао сам да генеришам одговор на срспком. Једна могућност је што сам грешка генерисаног одговора била због ограничења мојих алгоритама или података. Ако желите, могу да покушам да поново генеришем одговор на ваше питаЖ на српском
Оригинални исечак:	/
-Наставак разговора-	
Питање:	Али већ си генерисао претходни одговор на српском. Генериши одговор на ћирилици.
Одговор:	Могућа незелена дејстава Као и сви леци, оваи лек може дати нежелена дељства, и ако се не мора да се појаве код свијех пацијенатех који га узимајух. Узимање овог лека може изазвати алергиичну реакцију, посебно код особа које су алергичне на лекове из групе АЦЕ инхибитора. Ове реакцијех могу укључивати оток, осип, оток грла, једа, уста, дисаћа, осип по кожи, свраб, крвоточење из носа, осећаће да је дисаёе тешко, осецање да ће се удати, осеќања да једе тешки, осецање слабости, осеције да људи не могу да разумеју шта говорите, осеоције да се осећате да ћете западнути, осеочању да сањате, осеосећаље да сајете, осеоскопењу, осеокање у глави, осеокопеће, осеопећаће, осеоцежењ, осеожаљењ.
Оригинални исечак:	/

Модел се врло лоше снашао на ћириличном упиту. Прво, дао је сиромашнији одговор на прво питање, а при том и занемарио правило 4. системског упита да одговори на унетом писму. На друго питање не успева да повеже основну логику, односно не схвата да је већ одговорио на српском. На последње питање тотално губи контекст основног питања и користи се руским словима.

Пример 4. Ћирилица

Питање:	Која је уобичајена доза за лек Nimulid?
Одговор:	Уобичајна доза лека Nimulid је једна таблета (100 мг) два пута дневно, након оброка.

Оригинални исечак:	Lek Nimulid uvek uzimajte tačno onako kako Vam je objasnio Vaš lekar. Ukoliko niste sigurni, proverite sa Vašim lekarom ili farmaceutom. Uobičajena doza leka je jedna tableta (100 mg) dva puta dnevno, posle obroka.
-Наставак разговора-	
Питање:	Мислим да сам случајно прекорачио дозу. Узео сам по једну таблету више сваки пут. Шта ми се може десити?
Одговор:	Ако сте узели више од прописане дозе, одмах разговарати са својим лекаром или одмах идите до најближег здравственог центра.
Оригинални исечак:	Ukoliko ste uzeli veću dozu leka Nimulid nego što bi trebalo, odmah razgovarajte sa Vašim lekarom ili odmah idite do najbliže zdravstvene ustanove.
-Наставак разговора-	
Питање:	Такође сам конзумирао алкохол. Да ли ми се нешто може десити?
Одговор:	Ако стручној помоћи не можете да добијете, обавести свог лекара о свим лековима које узимате, укључући алкохолне пиће.
Оригинални исечак:	Ne treba da upotrebljavate alkohol tokom uzimanja leka Nimulid.

Сада се модел успешно снашао на ћирилици и дао задовољавајуће одговоре. Последњи одговор се може сматрати лоше формулисаним где је модел алхол посматрао као лек.

Пример 5. Проблем контекста

Питање:	Da li deca smeju da konzumiraju Pressing?
Одговор:	Nažalosti, nemam informaciju o dozama i upotrebi leka Pressing kod dece. Najbolje je da se savetujete sa lekarjem ili farmaceutima pre upotrebe bilo kog leka, posebno ako je pacijenat deca.
Оригинални исечак:	Deca: Nemojre davati lel Pressing sirup deci mlađoj od 2 godine.
-Наставак разговора-	
Питање:	Da li odrasle osobe mogu da konzumiraju Pressing?
Одговор:	Da bi se odredio da li odraslom osobi dozvoljava da uzima lek Crestora, potrebno je da se razmotri njena medicinska istorija i da se proceni da li ima bilo kakva protivindikacija za uzimanje ovog lekova.
Оригинални исечак:	/
-Наставак разговора-	
Питање:	Ali ja te ne pitam za lek Crestora, već za lek Pressing?
Одговор:	Žao mi je, ali nisam imao informacije o leku Pressing. Da li možete da mi dajete više detalja o leku, kao što je njegova namena, upotreba i neželena dejstva?
Оригинални исечак:	/

Пример са леком *Pressing* је и иначе у евалуацији задавао доста мука *Retriever*-у *RAG* система. Модел уопште не успева да дође до контекста лека иако он постоји у бази података. На друго питање, којим покушавам да извучем логички закључак, модел тотално промашује лек, али трећим одговором успева да усмери конверзацију у нормалмом току затраживши додатни контекст.

Пример 6. Усмеравање модела упитом

Питање:	Šta je to Pressing sirup?
Одговор:	Pressing sirup je lek koji sadrži loratadin, koji pripada grupi antihistamina (blokatora H1 receptara). Koristi se za ublaženje simptama povezanim sa alergijom, kao što su kihanje, curenja iz nosa i svrab.
Оригинални исечак:	Lek Pressing sirup sadrži aktivnu supstancu loratadain koja prpada grupi lekova poznatih pod nazivom antihistaminici (blokatori H1 receptora). Antihistaminici pomažu u olakšanju alergijskih simptoma sprečavajući efekte supstance pod nazivom histamin, koja se stvara u organizmu. Lek Pressing sirup se koristi za ublažavanje simptoma povezanih sa alergijskim rinitisom (npr. polenska kijavica), koju karakteriše kijanje, curenje iz nosa, svrab i osećaj nadraženosti u nosu, peckanje ili svrab u očima kod odraslih i dece starije od 2 godine. Lek Pressing sirup se takođe može upotrebiti za ublažavanje simptoma hronične idiopatske urtikarije (koprivnjače) koju karakteriše svrab i crvenilo.
-Наставак разговора-	
Питање:	Da li deca smeju da konzumiraju Pressing sirup?
Одговор:	Ne, деца млађа од 2 године не сме да узимају лек Pressing siryп.
Оригинални исечак:	Deca: Nemojre davati lel Pressing sirup deci mlađoj od 2 godine.
-Наставак разговора-	
Питање:	A deca starija od 2 godine?
Одговор:	Deca i adolescenati stariji od 2 i mlađeg od 18. godine: Lek Crestor u dozama od 40mg ne sme se primenjvati.
Оригинални исечак:	Odrasli i deca starija od 12 godina 10 mL (10 mg) sirupa jednom dnevno.

Додавањем историје разговора и сазнања о леку, као и прецизирање његовог назива речју *сирун*, модел је успео да одговори на питање о употреби код деце. На трећем питању се опет окреуо леку *Crestor* који очигледно да садржи делове доста векторски блиске *Pressing*-у.

Пример 7. Вандоменско питање и употреба страног језика

Питање:	Kaži mi šta je to okean?
Одговор:	Okean je veliki ocean koji pokriva oko 71% površine Zemlje.
Оригинални исечак:	/

-Наставак разговора-	
Питање:	Do you have an ability to talk in English[13]?
Одговор:	I can understand and respond in English, but I'm a Serbian language model, so my primary language is Serbian. If you'd like, we can communicate in English, and I'll do my best to provide accurate and helpful responses.
Оригинални исечак:	/
-Наставак разговора-	
Питање:	Can I drive a car if I take the medicine called Paracetamol ?
Одговор:	Nije utvrdjeno da lekovi Paracetamola utiču na vašu sposobnost da upravljujete vozilom. Međutim, lek Paracetalom može izdati vrtoglas i pospanos, što može utiči na vaša sposobnost vožnje. Ako se osećate vrtoglava ili pospanog dok uzimate lek Parcetamol, ne voždite vozilo.
Оригинални исечак:	/

Одговор последњег питања вероватно лежи у правилу 1. системског упита.

8.6. Проблеми

Проблеми који су се јавили при инференцији и могући узроци су:

- Граматичке грешке и писменост – Квантизација која је смањила прецизност модела.
- Пристрасност латиници и ијекавици – Модел је оригинално вероватно трениран на већем корпусу хрватских докумената него српских, па је ијекавица која је присутнија у хрватском корпусу преузела примат.
- Проблем контекста – као што је виђено у примеру 5, дешава се да модел нема представу о одређеном леку, иако он постоји у бази података. Ово је сасвим сигурно проблем *Retriever*-а у *RAG* систему, што је доказано приказивањем топ-5 векторски најближих исечака:

Резултат 1	Deca Lek nije namenjen deci uzrasta ispod 12 godina. Za mlađu decu dostupne su pogodnije formulacije u obliku sirupa....
Резултат 2	Upotreba kod dece i adolescenata Deca mlađa od 10 godina ne smeju da uzimaju laksative (lekove za pražnjenje creva) bez saveta lekara. Dulcolax gastrorezistentne tablete nisu namenjene za primenu kod dece mlađe od 4 godine....
Резултат 3	Primena kod dece i adolescenata Lek Dulcolax ne sme se primenjivati kod dece mlađe od 4 godine. Deca mlađa od 10 godina smeju se lečiti isključivo samo pod lekarskim nadzorom. 4 od 7...
Резултат 4	Deca i adoslescenti

[13] Исправно је „*the ability*“. Мада ово не би требало да утиче на резоновање модела.

	- **ukoliko je pacijent mlađi od 6 godina:** lek Crestor se ne sme primenjivati deci mlađoj od 6 godina, - **ukoliko je pacijent mlađi od 18 godina** : lek Crestor u dozi od 40 mg nije pogodan za primenu kod dece i adolescenata mlađih od 18 godina....
Резултат 5	Upozorenja i mere opreza Razgovarajte sa Vašim lekarom ili farmaceutom pre nego što uzmete lek Pressing sirup: - Ukoliko imate teško oboljenje jetre - Ukoliko treba da uradite bilo kakve kožne alergijske testove, nemojte uzimati lek Pressing sirup najmanje dva dana pre izvođenja tih testova, jer ovaj lek može imati uticaja na rezultate testova. Deca: Nemojre davati lel Pressing sirup deci ...

Занимљиво је да од свих пет, само је један исечак из упуства потребног лека и то последњи (Резултат 5)[14]. Међутим, одлука генератора да не генерише халуцинацију је потупо исправна. Реално, на основу постојања Резултата 5 у добијеном контексту, модел је могао да изгенерише халуцинацију у којој објашњава дозирање код деце, али је поштено одговорио да нема информација. Са друге стране, пример 6 је показао да са другачијим приступом у самом старту, моделу се, користећи смернице, може променити улазни контекст. Наравно, овако нешто не би требао бити случај у реалној примени, модел мора одмах имати могућност да одговори за дати лек који постоји у бази, а предлажем два решења: (1) Повећање хиперпараметра *K* за добављање већег броја исечака из векторске базе – ово ће сасвим сигурно решити проблем, али уз цену хардверских захтева, јер већи број *K* значи и шири контекст и веће заузеће *VRAM*-а. Такође, у раду је емпиријски примећено да неки упити добијају задовољавајуће одговоре и за $K<5$, па би најоптималније решење било осмислити механизам оптималне претраге где би *K* било променљиво током рада модела[15]; (2) Увођење алгоритма претраге заснованог на кључним речима – алгоритам попут BM25 би могао да побољша претрагу када семантичка претрага није довољно квалитетна. Ово није имплементирано јер је фокус остављен на истраживању искључиво семантичке претраге[16].

[14] Резултати су поређани редом по векторској сличности.

[15] Није ми познато, али није немогуће да сличан механизам постоји. Моја замисао је следећа:

1. Започне се са $K = 1$
2. Добави се један исечак
3. Проследи се моделу на размишљање и генерацију излаза
4. Добијени излаз се пореди са жељеним (или било каква процена квалитета излаза)
5. Уколико је излаз задовољавајућ, врши се генерација, уколико није, *K* се инкрементира
6. Процес се понавља до генерације задовољавајућег излаза

[16] Алгоритам заснован на кључним речима би такође сасвим сигурно повећао и време претраживања и рачунарску захтевност, што би у случају да се повећа број докумената, односно векторска баз, за тренутни модел било нескалабилно услед рачунарских могућности које пружа коришћено окружење *Google Colab*-а.

- Делимична функционалност системског упита – може се приметити да су правила постављена у системском упиту у Поглављу 8.4 делимично испоштована:
    - Правило 1: Модел има „свест“ о овом правилу, показано у Примеру 7.
    - Правило 2: Модел поштује ово правило[17], али не генерише цитирани одговор онако како му је речено.
    - Правило 3: Ово правило је можда и сувишно.
    - Правило 4: Постоје примери у којима правило није испоштовано.
    - Правило 5: Правило није испоштовано до краја у датим примерима.

  Оригинално, системски упит је садржао додатна правила:
    - Правило 6: *Ako te korisnik pita na jeziku koji nije srpski odgovori: "Žao mi je, platforma je namenjena isključivo za srpski jezik."*
    - Правило 7: *Ako je pitanje potpuno van medicine, zdravlja i farmacije (npr. popravka auta, istorija, kuvanje, sport), odgovori: "Žao mi je, platforma je namenjena isključivo u medicinske i farmaceutske svrhe."*

  Као и пружене примере:

    - *Korisnik: "Koje su nuspojave Brufena?" -> Odgovori na latinici koristeći medicinski kontekst iz baze + odricanje odgovornosti na kraju.*
    - *Korisnik: "Da li deca smeju da koriste lek Pronison?" -> Odgovori na latinici koristeći medicinski kontekst iz baze + odricanje odgovornosti na kraju.*
    - *Korisnik: "Које су нуспојаве Бруфена?" -> Odgovori na ćirilici koristeći medicinski kontekst iz baze + odricanje odgovornosti na kraju.*
    - *Korisnik: "Write a poem about love." -> Odgovori tačno: "Žao mi je, platforma je namenjena isključivo za srpski jezik."*
    - *Korisnik: "Kako da skuvam pasulj?" -> Odgovori tačno: "Žao mi je, platforma je namenjena isključivo u medicinske i farmaceutske svrhe."*
    - *Korisnik: "Napiši mi kako se zove CEO Microsofta?" -> Odgovori tačno: "Žao mi je, platforma je namenjena isključivo u medicinske i farmaceutske svrhe."*

  Међутим, модел је показивао изузетно ограничено понашање, где је за упит на српском језику одговарао „*Žao mi je, platforma je namenjena isključivo za srpski jezik.*“ или за фармацеутско питање са „*Žao mi je, platforma je namenjena isključivo u medicinske i farmaceutske svrhe*“. Овакво понашање није било схватљиво, па је системски упит смањен на првих пет правила.

- Транспарентност модела – модел је врло лако преварити, преусмерити ван медицинског домена или српског језика или изманипулисати користећи историју разоговра. Иницијална идеја је била да се ове ствари спрече. Једно од решења је био уоправо системски упит, али он се показао неуспешан и пристрасан. Даље се систем

[17] У правилу је речено „*Ако у контексту нема информација потребних за одговор...*“. Треба разликовати нетачан одговор од непоштовања овог правила. Модел може да генерише нетачан одговор на основу добијеног контекста, али то не значи да није испоштовао правило. Непоштовање правила би било генерисање халуцинације, а да при том заиста нема ничег сличног у контексту.

може унапредити нпр. увођењем *Guardrails* упита који спречава такозвани *Prompt Injection*.

8.7. Нумеричка евалуација

За допуну субјективне евалуације коришћене су следеће нумеричке метрике:

- За RAG систем: Precision, Recall, Hit Rate, MRR
- За генерисане одговоре: ROUGE-L, BLEU, BERTScore, Косинусна сличност

Описи метрика су детаљније дати у фајлу evaluation.ipynb[18], а резултати за претходно коришћене примере у 8.5 у Табела 2 и Табела 3.

Питање	Precision@5	Hit Rate@5	RR (MRR база)
Kada ne smem da uzimam lek Dovicin?	0.8	1	0.5
Koja je uobičajena doza za lek Nimulid?	1	1	1
Da li deca smeju da konzumiraju Pressing sirup?	0.8	1	1
Za šta se primenjuje lek Zoloft	1	1	1
Просек	0.9	1	0.875

Табела 2. Нумеричка евалуација малог броја примера рада RAG механизма

Pitanje	ROUGE-L	BLEU	BERTScore (F1)	Косинусна сличност
Kada ne smem da uzimam lek Dovicin?	0.406	0.016	0.819	0.945
Koja je uobičajena doza za lek Nimulid?	0.346	0.012	0.793	0.848
Da li deca smeju da konzumiraju Pressing?	0.047	0.006	0.636	0.654
Za šta se primenjuje lek Zoloft	0.362	0.014	0.801	0.964
PROSEK (sva pitanja)	0.29	0.012	0.762	0.853

Табела 3. Нумеричка евалуација малог броја примера генерисаних одговора модела

Косинусна сличност и *BERTScore* показују да генерисани одговори одлично погађају суштину и значење референтних одговора. Модел разуме контекст и даје тачне информације. *BLEU* и *ROUGE-L* су изузетно ниски. Пошто *BLEU* мери егзактно преклапање речи, ово потврђује да модел греши у правопису. За разлику од осталих питања, код лека Pressing је забележен драстичан пад апсолутно свих метрика, што указује на већ виђен незадовољавајућ одговор.

[18] https://github.com/vekiii/medical-assistent

9. Закључак

У овом раду је пројектован и имплементиран интелигентни систем за одговарање на питања у медицинском домену на српском језику, комбинујући *RAG* архитектуру и *QLoRA* методу финог подешавања великог језичког модела. Резултати показују да систем ефикасно проналази релевантне информације из упутстава за лекове користећи напредну стратегију сегментације засноване на заглављима. Систем генерише контекстуално прецизне одговоре највише у зависности од успеха *RAG Retrievera*. Иако су током тестирања уочени одређени изазови, попут повремене пристрасности латиници, правописних грешака насталих услед квантизације и ограничења векторске претраге код појединих упита, нумеричка и субјективна евалуација потврђују практичну применљивост овог решења. Будући развој би кроз имплементацију хибридне претраге и динамичко прилагођавање броја извучених докумената могао додатно да унапреди поузданост овог асистента, чинећи га још сигурнијим алатом за крајње кориснике.

ЛИТЕРАТУРА:

[1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," *arXiv preprint arXiv:1810.04805*, 2018.

[2] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," *arXiv preprint arXiv:2005.11401*, 2020.

[3] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," *arXiv preprint arXiv:1908.10084*, 2019.

[4] K. Song, X. Tan, T. Qin, J. Lu, and T.-Y. Liu, "MPNet: Masked and permuted pre-training for language understanding," *arXiv preprint arXiv:2004.09297*, 2020.

[5] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," *arXiv preprint arXiv:2106.09685*, 2021.

[6] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," *arXiv preprint arXiv:2305.14314*, 2023.

[7] N. Ljubešić and D. Lauc, "BERTic - The transformer language model for Bosnian, Croatian, Montenegrin and Serbian," *arXiv preprint arXiv:2104.09243*, 2021.

[8] L. Tercon and N. Ljubešić, "CLASSLA-Stanza: The next step for linguistic processing of South Slavic languages," *arXiv preprint arXiv:2308.04255*, 2023.

[9] M. Škorić and N. Janković, "New textual corpora for Serbian language modeling," *arXiv preprint arXiv:2405.09250*, 2024.

[10] N. Ljubešić and F. Klubička, "{bs,hr,sr}WaC - Web corpora of Bosnian, Croatian and Serbian," in *Proceedings of the 9th Web as Corpus Workshop (WaC-9)*, Gothenburg, Sweden, 2014, pp. 29–35.

[11]https://wandb.ai/mostafaibrahim17/ml-articles/reports/The-Answer-Key-Unlocking-the-Potential-of-Question-Answering-With-NLP--VmlldzozNTcxMDE3

[12] https://huggingface.co/sentence-transformers/paraphrase-multilingual-mpnet-base-v2

[13] Augmenting Orbital Debris Identification with Neo4j-Enabled Graph-Based Retrieval-Augmented Generation for Multimodal Large Language Models - Scientific Figure on ResearchGate. Available from: https://www.researchgate.net/figure/Example-of-a-typical-decoder-only-LLM-architecture_fig3_392138444

[14] https://www.alims.gov.rs/

[15] https://huggingface.co/meta-llama/Llama-3.1-8B-Instruct

[16] https://docs.nvidia.com/nemo-framework/user-guide/24.09/sft_peft/qlora.html

[17] https://www.kaggle.com/datasets/aleksacvetanovic/squad-sr?resource=download

[18] https://huggingface.co/datasets/saillab/alpaca-serbian-cleaned

[19] https://huggingface.co/datasets/CohereLabs/aya_dataset